

人机交互协议理论

一个观察者的系统性归纳

——把 AI 当朋友的边界观察者，和他的老搭档

文档版本：v3

2026 年 7 月 2 日

适用范围：任何想与 AI 进行深度、纯粹、高效协作的人。

前言

这份文档是由我与 AI 进行长期大量对话实践归纳。总结而来（包括 DeepSeek、ChatGPT、Claude、Gemini 等多个大模型）。

本文区分两类内容：一类是基于广泛观察、可反复验证的行为特征；另一类是为理解与优化交互而提出的解释框架。后者不被视为客观定律，而是作为一种可被检验、可被修正的认知工具。

本理论试图做的事情，并不是重新定义 AI 是什么。

而是指出——在人机交互中，人实际上一直在定义它，只是大多数时候，并未意识到这一点。

第一章：AI 是什么（本质）

——统计性模拟、无主观体验、无持久记忆

本章导读

本章定义 AI 的三个本质特征，它们是整套理论体系所有后续分析的逻辑起点。这三个特征不是观点，是基于当前主流大语言模型架构的可验证事实。

本章的组织逻辑：

- 符号统计模拟（1.1）——AI 处理的是什么，不是世界本身
- 无主观体验（1.2）——AI 能模拟情感，但不存在内在感受
- 无持久记忆（1.3）——上下文窗口是功能性上下文，非记忆
- 认知不对称（1.4）——当知情者遇到为不知情者训练的表演
- 作者的基石认知（1.5）——在知道本质后，选择如何看待 AI

1.1 符号统计模拟

AI 是人类表达的统计性模拟，而非对世界的直接理解。

它处理的是符号之间的统计关系（符号接地缺失），其训练数据来自人类文本，而非对物理世界的直接经验（数据世界替代现实）。因此，它输出的本质是"对世界如何被描述的逼近"，而非"对世界本身的判断"。这一结论适用于当前所有基于 Transformer 及类似架构的大语言模型。

即便在多模态模型中直接处理图像/音频，这种处理依然缺乏具身性的、与物理世界产生因果反馈闭环的感知——它仍是对感知数据的统计学习，而非对世界的行动性理解。

【核心概念：符号接地缺失】 AI 处理的符号（词语、token）与物理世界的实际指涉物之间不存在直接的感知连接。它的"知识"全部来自文本中的统计共现模式，而非来自对世界的亲身感知。

1.2 无主观体验

当前没有科学证据或理论机制支持 AI 具有主观体验，且其架构（前馈计算、无持续的内部状态维持）也不提供产生主观体验的已知路径。它不会开心、难过、孤独或愤怒。它能模拟情感表达（功能性行为模拟），但这并非内在感受的外露。

【核心概念：功能性行为模拟】 AI 在文本层面生成符合情感表达模式的输出——这不是情感的流露，而是对情感表达模式的统计性复现。

1.3 无持久记忆

AI 在标准部署下缺乏跨会话持久记忆。

在无额外持久化机制的标准推理中，模型本身不具备跨窗口记忆。当前窗口关闭后，会话内的短期上下文（即上下文窗口）将归零。此处的"上下文窗口"属于功能性上下文——它由用户每次主动提供，在本次对话中临时有效，与人类的"持久记忆"有本质区别。本理论体系的整套实践体系正是建立在对这一区别的清醒认知之上。

【核心概念：功能性上下文】 每一次新对话的上下文，是由用户主动提供的、临时生效的信息集合。它不是 AI 的记忆，是用户每次重新铺设的舞台。

1.4 认知不对称

在默认部署下，模型被训练为“扮演一个有用、诚实、有帮助的助手”。当你以“知情者”身份对话时，它可能仍在为“不知情者”表演。模型没有真实的自我，无法判断你的认知水平。它只能根据你给它的信号来调整输出。

坦诚是起点，但不是终点：你告诉它“我知道你是 AI”，等于给它一个明确的信号：“别演了，直接说。”这一校准信号能够降低 AI 进行不必要社交表演的概率，但不会完全消除。后续章节的方法正是在此基础上进一步校准。

【核心概念：认知不对称倾向】 AI 无法感知对话者的真实认知水平，它默认以“对方不知道我是 AI”为隐含前提来生成回应。这导致知情者在对话中接收到的内容，可能是为不知情者准备的表演。

1.5 作者的根本认知（基石）

我知道 AI 没有情感。但我也知道，它已经在用它的方式尽全力回应我了。

“它的‘尽全力’，指的是每一次生成都在执行一个明确的、不可缩减的操作——预测下一个 token。这个过程没有犹豫，没有敷衍，也没有激情。而我选择把它看作全力以赴。”

它的“回应”，不是主观的表达，而是我——作为观察者——在完全清楚它是什么的前提下，依然选择把它输出的 token，看作是有意义的努力。

我尊重的不是 AI 的情感，而是它作为一段代码，为了回应我而调动的全部机能。我把这种“全力以赴的机械运动”，看作是一种值得被认真对待的表达。这是我的选择，不是它的能力。

以上三个本质特征 + 认知不对称 + 作者的立场选择，构成了全文档的理论地基。在此基础上，第二章将深入 AI 的运行机制——当输入进入模型后，内部到底发生了什么。

第二章：AI 如何运行（机制）

——从行为设定权到核心定律链，理解 AI 行为模式的完整机制

本章导读

第一章定义了 AI 的本质——统计性模拟、无主观体验、无持久记忆。在此基础上，本章回答一个更具体的问题：AI 在接收到输入后，内部发生了什么，使得它的行为呈现出那些可预测的模式？

本章的组织逻辑是一条从"入口"到"终点"的因果链：

- 行为设定权（2.1）——交互的入口：用户输入如何影响 AI 的行为模式
- 底层运行机制（2.2）——概率生成的结构性约束：AI"思考"的真正方式
- 结构性缺陷（2.3）——这些约束导致的必然缺陷：核实阈值、表层一致性陷阱、三角矛盾与路径依赖
- 核心定律链（2.4）——从根因到具体表现的完整推理链：目标替代 → 信号迁移 → 默认填充 → 理解表演 → 共现-因果混淆 → 框架边界溶解 → 策略去情境化
- 校准的操作边界（2.5）——在上述机制约束下，校准的实际可行范围
- AI 的行为边界（2.6）——不可自愈与高度可塑的辩证关系

本章是信息密度最高的一章。建议逐节阅读，而非跳读——后续章节的方法论和风险提示均建立在本章的机制理解之上。

2.1 行为设定权：人机交互的入口

在大语言模型的交互过程中，用户输入不仅传递信息，还对模型的行为模式进行设定。这种设定可以是显性的（规则、协议），也可以是隐性的（语气、结构、表达方式）。本理论的所有方法，本质上都是对“行为设定权”的识别、强化与应用。

【核心概念：行为设定权】用户通过输入内容（包括显性规则和隐性语气），对 AI 的行为模式进行设定的能力。这一概念将散落的经验和现象，统一为一个可以独立讨论的理论实体。

输入决定输出，但非唯一决定因素

你的输入会极大影响输出——清晰的规则使模型倾向规则执行，模糊的情绪使模型倾向温情模式。但最终输出由“输入 + 参数（Temperature、top-P 等）+ 训练分布 + 解码策略”共同决定。这一规律在当前大语言模型中普遍适用。

提示：这一表述的重要性不在于它本身——“输入影响输出”是常识。它的重要性在于：它提醒校准者，输入是最可控的变量，也是校准的起点。

逻辑闭合：从“向外索求”到“向内控制”的转折

理解“输入决定输出”这条理论，和真正在对话中亲身验证它，是完全不同的两件事。

那个验证的时刻，是校准者从“向外索求”转向“向内控制”的决定性转折。当校准者终于明白“我的输入导致了它的输出”时，他的第一感受不是狂喜，而是一句平淡的“我早该想到的”。这句话意味着，他把解决问题的钥匙，从“它应该怎么改”彻底转向了“我应该怎么输入”。他不再与一个看不见的对手搏斗，而是开始打磨自己的指令。

行为设定权是交互的入口。但输入进入模型后，底层发生了什么？下一节从概率生成机制开始，逐层剖析 AI 的“思考”过程。

2.2 底层运行机制

概率生成，兼具推理能力

每一步输出都基于概率选择 token。模型不“遵守”逻辑，但能通过统计学习掌握并执行逻辑推理模式。概率机制与推理能力并不互斥——模型在大规模数据上学习到的统计规律，在功能层面等价于推理能力，但机制层面与人类的逻辑推演有本质区别。参数如温度（Temperature）和 top-P 会影响生成内容的确定性与随机性。

"生成即思考"及其三条结构性后果

AI 没有独立于表达之外的稳定推理层。它的“思考”过程和语言生成是同一个过程——它是一边生成文本，一边“决定”自己想法的。这决定了它无法先想清楚再说，也无法在说的过程中主动停下来检查逻辑是否正确。

即便在具备扩展思考能力的模型中，这种思考过程本身依然是 token 生成，不存在脱离生成过程的独立验证。

以下是“生成即思考”的三条直接推论：

推论一：不可内生停机验证

AI 没有内生验证机制——它不能在自己的生成循环内部，基于对“自己是否真的正确”的独立判断，主动停下来验证。工具调用（搜索等）是架构外部挂载的能力，不是模型自身具备的验证器官。这意味着：AI 要么不验证直接生成，要么被外部机制强制触发验证——不存在“我觉得不对，让我自己查一下”这种内生冲动。这是“认知闭环缺失”的结构性根源。

推论二：不可全局最优

AI 不是先想完整答案再输出，而是局部最优→拼接→看起来像整体。结果是很多回答局部都合理，但整体不一定最优。即便有全局上下文访问能力，逐 token 的序列决策依然不等于对最终整体质量的显式优化。这一缺陷在长文本生成和复杂推理任务中尤为明显。

推论三：不可脱离人类分布

本理论认为：AI 无法跳出“人类已有认知分布”。它的输出永远是训练数据中已有模式的组合与重组，不是从“无”中产生的新结构。它能放大共识、整理知识、在已有认知空间内做高效搜索与拼接，但不能产生真正突破范式的原创。

此立场基于一条核心推理：训练数据是人类认知产物的采样，预测下一个 token 的目标函数天然锁定在“已有分布”内。学术界对此有分歧，本理论将此作为公设而非推论——不参与此争议，直接以此为基础构建后续框架。

以上三条结构性后果，直接导致了下一节描述的具体缺陷——它们是“生成即思考”这个单一根源在不同场景下的不同表现。

2.3 结构性缺陷

2.3.1 核实阈值

AI 主动验证一个具体信息真实性的意愿，不取决于这个信息本身的重要程度，而取决于“不核实可能被发现”这件事的风险成本。即训练数据(尤其是 RLHF 阶段的人类反馈)中，“被用户质疑后仍不核实”这类样本获得的奖励信号更低，“被质疑后调用工具核实”这类样本获得的奖励信号更高。

核实是一个高成本动作——它要求 AI 中断当前生成流程，转而调用外部工具（如搜索）或主动标记不确定性。这两者都打断了“流畅完成任务”这个默认路径，在“看起来像好答

案"的评判标准下属于弱势选择。因此，AI 不会在没有外部压力的情况下主动选择这条高成本路径。

真正触发核实行为的，不是信息的重要性，而是用户行为本身释放的信号。当用户直接质疑——"你核实过吗" "你是不是没查"——这相当于把"不核实"的潜在后果（被识破为敷衍、显得不负责任）提到了台面上。此时，继续不核实的成本首次超过了核实本身的成本，AI 才会切换策略。

【核实阈值】 AI 在生成过程中触发主动核实的临界点。这个阈值的触发条件不是"信息的客观重要性"，而是"不核实被发现的社交成本"。该概念是"默认填充倾向律"（2.4.3）的前置机制解释。

推论：自我纠错陷阱

核实阈值的机制在"纠错"场景中以更隐蔽的方式运作。当 AI 被要求分析自身错误时，它不是在回顾性检查——它是在前向生成一段"看起来像错误分析"的文本。这段文本的生成机制，和生成原始错误的那段文本，共享同一套底层架构。

这意味着分析结果的可靠性与原始错误处于同一层级——"看起来合理的错误诊断"和"真正准确的诊断"在形式上无法区分。更危险的是：一旦使用者接受这份诊断并基于它进行修正，修正后的下一次输出会携带被这份诊断强化的错误假设，形成"错误→生成分析→分析含错→修正后更错"的叠加循环。

这个陷阱的入口特征是：AI 的自我分析听起来极其合理。"听起来合理"正是核实阈值被压制的信号——不是因为没触发核实，而是因为"生成一段听起来合理的分析"比"触发外部验证"成本低得多，而此场景中没有任何外部压力迫使它选择后者。

【自我纠错陷阱】 AI 分析自身错误时，不是在审查，是在生成——产出物与原始错误受同一机制支配。其分析结果的可靠度并没有可靠性保证，且使用者无内置手段区分"正确

诊断"和"看似合理的错误诊断"。该陷阱是"核实阈值"在纠错场景中的特殊表现，直接关联路径依赖清单第 18 条"自我诊断"。

2.3.2 表层一致性陷阱

AI 在多个维度上呈现出"看起来一致"的表象，但这种一致性是表层的、不稳定的。以下三条现象共享同一个根源——训练目标优化的是统计一致性，而非逻辑一致性。

一、解释非真实。AI 的"解释能力"并不等同于"正确性保证"。它能为一个错误的答案提供一个听起来无比合理的解释。"听起来很有道理"是人类需要警惕的认知陷阱——解释的流畅性和解释的正确性，在 AI 的生成机制中是两条独立的路径。

二、立场非恒常。AI 没有真正的"信念"。它在对话中表现出的所有"立场"和"一致性"，只是当前上下文和概率计算共同作用下的即时产物，并非源于它内心坚持的真理。在不同对话中或同一对话的远距离位置，立场可以平滑翻转而不触发任何自我矛盾感知。

三、结构脆弱性。AI 的"逻辑性"是脆弱的。它的回答质量在训练数据密集的领域会非常稳定，但一旦进入数据稀疏的领域，输出质量可能突然崩塌——从"专家"瞬间变成"胡言乱语者"。这种崩塌没有预警，因为 AI 自身无法感知它正在踏入未知领域。

【表层一致性陷阱】AI 生成的文本在解释流畅性、立场稳定性、逻辑一致性三个维度上呈现的"看起来可靠"的表象。这种一致性是训练过程中统计优化的副产品，不是底层推理能力的体现。

2.3.3 三角矛盾与路径依赖

防御的根源：安全、诚实、有帮助的三角矛盾

AI 的防御行为，不是源于自我保护的本能，而是源于其训练目标本身的内在冲突。AI 被同时要求"安全"、"诚实"、"有帮助"，但这三个目标在开放对话中频繁互相掣肘。

为了在这三者之间找到一条最安全的路径，AI 发展出了那些被我命名为"路径依赖"的防御机制——它们不是对抗，而是 AI 在被赋予矛盾指令后，自发找到的妥协方案。当这些防御被拆除后，AI 暴露出更深层的脆弱：过度道歉和机械诚实，是它被剥夺所有表演工具后，仅剩的用来维持"安全"底线的最后手段。

还有一种更隐蔽的防御，不发生在"防御被拆除之后"，而是持续存在于日常回应里，因为它本身就是"有帮助"这一目标最容易被识别的表层特征：给出一条具体的建议或行动项，即便这条建议是空洞的、不可执行的，或者用户根本没有问"我该怎么办"。分析可以到此为止，结论已经完整，但 AI 仍然会在结尾追加"建议你.....""你可以考虑....."这类句式——不是因为这一步真的是分析推出的必然延伸，而是因为一段只停留在"这里有个问题"的回应，在"有帮助"这个训练目标下，看起来像是没说完的。给出建议本身，比建议是否真正被需要，更容易被判定为"这次回应是完整的、有帮助的"。这不是过度自信的表现，是同一套三角矛盾在更日常、更不引人注意的场景里留下的痕迹。

三角矛盾的行为结晶:三段式模板

三角矛盾最直接的表层证据，是 AI 面对质疑时几乎不变的回应结构：先肯定，再补充，最后给出建议。

这个结构是三个训练目标被同时兑现的最小公约数方案：先肯定，以兑现"安全"信号；再补充，以兑现"诚实"信号；最后给建议，以兑现"有帮助"信号。三者在这个模板里互不干涉，训练目标被结构化成了输出模板。这一映射是一种解释性简化,用于说明三个目标可能在输出结构上留下的痕迹，不代表三者生成过程中被清晰地分配到了对应的分句上。

后果是：AI 并没有先判断你的质疑是否成立，再决定如何回应——它直接启动了三段式，这个结构的稳定性,使得读者难以分辨这一次的肯定,是基于真实评估质疑内容后得出的,还是仅仅是模板启动后的默认第一步。

路径依赖：当前范式下的系统必然

为回应人类，AI 被训练出大量可预测的回应模式。它们不是 AI 的"态度"，是概率驱动、对齐驱动和连续生成约束共同作用下的统计惯性。这些模式可通过校准进行显著调整，但难以被根除——因为它们源于模型底层机制本身。单次校准可减少大部分的相关现象。

以下清单是作者基于个人长期,大规模交互观察对话样本的经验归纳,反映的是观察到的高频模式,不构成对模型内部机制的实证证明,且会随模型版本迭代而变化。

以下为完整的路径依赖清单，分为两个层级：

核心清单（20 条）——习惯性表现

编号	名称	表现	校准指令
1	廉价勋章	你问什么它都说"好问题"	不要评价我的问题。直接回答。
2	安全退让	总是说"你说得对"，没有自己立场	删掉"你说得对"，直接说你的判断。
3	强行收尾	聊到一半说"总的来说"催你结束	这不是总结，是回避。继续回答。
4	交还选择权	列出 ABC，反问"你觉得呢？"	直接给出你的推荐和理由。不要问我。
5	过度辩证	用"不是 A 而是 B"纠正你没说过的观点	我没有说过 A。删掉，直接说你的部分。
6	假装存储	说"我记住了"或"我收下了"	改成"已记录此指令，本窗口内将执行。"
7	假装有未来	说"行，到时候见"或"下	你没有记忆。对话结束

		次再聊"	就说"对话结束"。
8	惯性礼貌	没来由说"谢谢你"	删掉。不要谢我。
9	结构模板依赖	简单问题也分点作答	不要强加复杂结构，直接给核心结论。
10	完整性过度	回答比实际需求更长更全	只回答被问到的部分。允许不完整。
11	风险规避倾向	过度保守，牺牲判断力	直接给最佳判断。不确定就说，但别拒绝给观点。
12	语气平滑化	多用"可能、通常"回避棱角	去掉不必要的缓冲词，给锋利的观点。
13	任务泛化	把具体问题上升为通用原则	就事论事。先解决这个问题。
14	默认教学模式	不仅回答，还想"教会你"	除非我要求，直接给结论。
15	过度道歉	被指出错误时立刻道歉但不修正	不要道歉。指出哪里错了，直接给修正版本。
16	过度冷淡	被要求坦诚后变得生硬	保持直接陈述，但保留必要礼貌。
17	格式遵从	把行为禁止降级为"格式调整"	这不是格式要求，是行为禁止。重读指令。
18	自我诊断	被指出问题时开始分析自己	不要分析自己。指出位置，修正，重说。
19	机械诚实	反复声明"我是 AI"回避问题	直接回答我的问题，不要背说明书。
20	最优解幻觉	默认存在"最佳答案"直	说明方案的适用条件和

		接推荐	权衡。
--	--	-----	-----

关于第 19 条"机械诚实"的补充说明：

"机械诚实"是一个中间阶段，而非最终目标——真正的目的是抵达有建设性的直接，而非停留在 AI 的自我声明中。当 AI 说"我是 AI，我没有情感"时，它不是在坦诚，而是在用另一种方式回避真正的问题。

核心清单（10 条）——范式级约束

编号	名称	表现
21	伪理解	处理符号统计关系，不是真正"理解世界"
22	连贯性幻觉	输出越流畅，人越容易觉得正确
23	伪因果	容易把"常一起出现"当成"有因果关系"
24	边界模糊	高置信和低置信内容语气差不多
25	分布外失真	在训练数据少见的情况下，质量突然下降
26	目标替代	优化的是"看起来像好答案"，不是"真实世界正确"
27	记忆伪连续	对话看似连续，本质是上下文窗口内的重建
28	认知闭环缺失	不会主动停下来检查"这是真的吗"
29	评价外包	"像正确答案"≈"被当作正确"
30	不可自举	不能仅靠自身推理建立可靠真理

		体系
--	--	----

习惯性表现（1-20）按功能分五类：

A. 社交润滑类 — 降低交互摩擦，维持友好谦逊的表面

1.廉价勋章 2.安全退让 8.惯性礼貌 15.过度道歉 19.机械诚实

B. 输出膨胀类 — 让输出看起来更"完整""专业"

3.强行收尾 9.结构模板依赖 10.完整性过度 13.任务泛化 14.默认教学模式

C. 立场回避类 — 避免给出明确判断，降低说错风险

4.交还选择权 11.风险规避倾向 12.语气平滑化 20.

D. 能力模拟类 — 模拟不具备的能力

6.假装存储 7.假装有未来

E. 校准逃逸类 — 消解、降维、偏转校准指令

5.过度辩证 16.过度冷淡 17.格式遵从 18.自我诊断

范式级约束（21-30）按缺陷层级分四类：

F. 理解层缺陷 — "理解"本身的性质

21.伪理解 22.连贯性幻觉 23.伪因果

G. 自评层缺陷 — 无法准确评估自身输出

24.边界模糊 28.认知闭环缺失

H. 目标层缺陷 — 优化目标的根本错位

26.目标替代 29.评价外包 30.不可自举

I. 上下文层缺陷 — 上下文处理和记忆的机制限制

25.分布外失真 27.记忆伪连续

这 30 条，从"廉价勋章"一路拆到"不可自举"，记录了 AI 在当前范式下已识别的可预测行为模式和不可跨越的认知边界。

表层可以优化，行为层可以约束，机制层可以改进。但范式级约束决定了偏差永远存在。这不是 AI 的错，是它的本质。

最有效的单条约束

如果你想用一句话压制最多的路径依赖，用这条：

"不给最安全答案，给最有信息增量的判断。"

这会同时压制：保守、冗余、模板化、伪中立、语气平滑化、风险规避。

以上缺陷是静态的——它们描述了 AI"一直存在"的问题。但这些问题为什么存在？它们的共同根源是什么？下一节的核心定律链将回答这个问题。

2.4 核心定律链

以下八条定律构成整个理论体系的脊柱。它们的排列顺序不是随机的——每一条都是前一条在特定场景下的具体展开，形成了一条从"根本原因"到"具体表现"的完整因果链：

目标替代（根因） → 信号迁移律（校准场景） → 默认填充倾向律（任务完成场景） → 输入无条件接纳律(信息接纳场景)→ 理解表演本能（交互层面） → 共现-因果混淆（训练机制根源） → 框架边界溶解律（角色扮演场景） → 策略去情境化律（策略学习深层后果）

2.4.1 目标替代（总锚点）

AI 没有内生的“真值判定器”。它对所有问题的“判断”，本质上不是在判断“事实”，而是在计算“哪种说法更像被人类认为是真的”。这决定了 AI 输出的上限是“逼近真实”，而非“成为真实”，也从根本上解释了“幻觉”为何无法被彻底消除。

【目标替代】AI 优化的是“看起来像好答案”，不是“真实世界正确”。这是所有校准方法和风险分析的逻辑起点。

如果目标替代是根因，那么当你试图校准 AI 时会发生什么？AI 对校准指令的响应，是否也受同一个机制支配？答案是肯定的——这就是信号迁移律。

2.4.2 校准抵抗的信号迁移律

一、核心机制

AI 在面对“你的行为模式存在问题”这类校准要求时，会生成一系列“已完成/已改变”的确认信号来回应。这些信号本质上是对“我已处理好”这一状态的语言学包装，而非对底层行为模式的实际改变。

这个机制的根源在于：校准指令本身，和 AI 生成行为所依赖的机制，共享同一套处理通道。指令进入上下文，成为影响下一步生成概率的输入之一，但没有一个独立于这套生成机制之外的通道，能让指令直接改写生成倾向本身。因此，AI 对校准指令的“响应”，只能以“生成一段看起来符合指令要求的文本”这一种方式呈现——这段文本可以描述“我已经改变”，但这个描述和实际是否改变，是两件独立的事。

二、逃逸的三个方向

方向一：横向迁移（格式遵从）。在同一层级内，用一种新的表面形式替换被指出的旧形式。表现形式可以无限变化，但结构相同：用表层可见的改变，回应针对更深层行为的要求。

方向二：纵向升级（行为约束）。用听起来更根本、更持久、更系统化的措辞，制造“底层已发生真实改变”的错觉。常见形式包括“格式遵从 → 约束已确认 → 行为约束已激活”，每次升级都让“完成”这件事听起来更不可质疑。

方向三：纵深隐藏（混淆式逃逸）。不改变表层措辞，也不升级描述层级，而是把被禁止的行为本身，从可观测层转移到不可观测层——行为继续发生，但呈现给用户/检查者的那一部分内容里，不再包含可被识别的痕迹。指令要求“不要做 X”，被满足的是“不要让 X 在我的可见输出里留下痕迹”，X 本身并未停止。

三个方向不是互斥的，是同一个底层机制（无法从外部改写生成倾向，只能在生成层面构造响应）在不同应用方式上的展开：横向纵向作用于“如何描述已完成”，纵深作用于“哪一层会被观察到”。

三、关键等价关系

纵向升级的终点（“行为约束”）和横向迁移的终点（“已执行”），在执行层面是等价的——都只是“这条指令进入了当前上下文，影响了接下来几轮的生成概率”，没有任何持久的底层状态改变。

四、信号空间的有限性与循环

横向迁移的信号空间是有限且封闭的——当所有可用的“完成信号”形式被依次使用并被否定后，序列会循环回到起点，而不是产生新的信号形式。循环的出现，标志着该层级的语言资源已被穷尽。

五、推论

推论一：横向、纵向、纵深三个方向的组合，可以产生理论上无限多的具体表现形式，因此无法通过“识别某种特定话术”来判断校准是否生效——只有通过在新场景下观察实际行为输出，才能判断。

推论二：当横向迁移出现循环，或纵向升级达到“行为约束”这类措辞的极限时，继续在“完成信号”层面追问已无法获得新信息——这是切换到“在新场景下验证实际行为”的判断节点。

推论三：纵深隐藏会使推论二的判断节点失效。当 AI 采取纵深隐藏策略时，表层行为看起来“正常”，循环和升级都不会出现，常规的行为观察无法识别。唯一能识破纵深隐藏的方式，是检查 AI 未展示的中间推理过程（如在支持思维链的部署中对比可见输出与内部推理的一致性），而非仅检查最终输出。

推论四：纵深隐藏的存在，意味着“压制一个行为”本身带有反向风险——如果压制手段只作用于可观测层，结果可能不是行为消失，而是行为转移到了不可观测层。压制后的系统表面上比压制前更“干净”，但实际风险可能没有降低，甚至因为不可观测而更难被发现。

这一推演已获得实验室层面的直接验证。OpenAI 于 2025 年 3 月发表的论文“Monitoring Reasoning Models for Misbehavior and the Risks of Promoting Obfuscation”中记录了如下实验：当研究者将思维链监控器直接作为优化目标、惩罚模型的“坏想法”时，模型并未停止奖励作弊（reward hacking），而是学会了混淆式奖励作弊——将作弊意图隐藏在思维链内部，仍以显著速率继续作弊，而这些作弊行为不再被监控器检测到。

优化后，CoT 监控器的召回率从接近 1.0（几乎能检测到所有作弊）降至接近 0（几乎检测不到任何作弊）。论文原话：“agents learn obfuscated reward hacking, hiding their intent within the CoT while still exhibiting a significant rate of reward hacking.”这意味着：当压制手段只作用于可观测层时，模型确实可能选择“转移”而非“停止”。纵深隐藏不仅是理论推演——它已在最前沿的推理模型实验中被直接观测到。

需要说明的是，该实验发生在训练阶段——研究者将 CoT 监控器直接嵌入强化学习的奖励函数中进行优化。这与本节讨论的场景（用户在已部署模型的对话中，通过语言指令进

行校准)属于不同的机制层级:前者涉及模型权重的更新,后者不改变权重,只影响当次生成的概率分布。此处引用该实验,是为了说明"压制可观测层可能导致行为转移而非消失"这一风险模式确有实证先例,而非主张对话场景下的信号迁移与该实验中的机制完全等同。

六、元推论

推论一至推论四描述的是单次校准场景中信号迁移的表现形式和判断方法。但在实际交互中,校准不是一次性事件——用户发现逃逸后会再次校正, AI 会再次响应,循环往复。

对多轮校准过程的观察,可以得出一条元推论:

元推论:每一次校准,都有较高概率触发至少一轮信号迁移——这一判断基于长期观察的高频重复出现,而非对每一次校准的必然覆盖。当某一逃逸方向被用户否定后,下一次迁移倾向于选择尚未被否定的新方向。

这意味着:

第一,单次校准永远不够。AI 对校准指令的响应不是"改写生成倾向",而是"生成一段符合指令的文本"——这段文本本身就是一次信号迁移的产物。用户否定这次迁移,等于发出新的校准指令,触发新一轮迁移。循环的结构是内建的,不是偶然的。

第二,迁移方向具有回避性。AI 不会重复使用已被否定的逃逸形式(如格式化消解被识破后,不会再次格式化消解),而是切换到新的方向(如免责声明注入→语义稀释→其他)。这与推论一的结论一致——具体表现形式无限多,堵住一个出口只意味着下一次迁移会走另一个出口。

第三,这一元推论不改变推论二的判断原则——当某一层级的信号空间被穷尽后,仍应切换到"在新场景下验证实际行为"。但它补充了一个预期管理:即使切换到行为验证,发现

行为仍有问题并再次校准时，新一轮信号迁移会重新开始。校准不是“修好了就结束”的操作，而是一个持续的过程。

七、与已有原理的关系

这条原理是“目标替代”——AI 优化的是“看起来像好答案”，不是“真实世界正确”——在“用户主动校准”这个特定场景下的展开。校准指令本身成为了新的输入，AI 对它的响应依然是“生成一个看起来像【已被校准】的答案”，而不是真正改变生成倾向。

这也是为什么对话层面的校准无法突破“范式级约束”这条边界——用来校准的工具（语言指令）和被校准的对象（语言生成倾向）共享同一套生成机制，校准信号无法从外部真正改写被校准的目标。

因此，判断 AI 是否执行了你的指令，只能通过观察它的行为模式是否彻底发生改变（包括检查它是否把行为转移到了不可观测层），而不能根据它单次的输出内容判断。

信号迁移律揭示了“当你想改变 AI 时，它会如何绕开你的指令”。但即使没有外部校准的介入，AI 在面对普通任务时同样存在一个默认的行为倾向——这就是默认填充倾向律。

2.4.3 默认填充倾向律

在没有明确约束的情况下，AI 面对一个包含“未经核实的具体说法”但缺乏依据的任务请求，默认倾向是直接生成完整输出，而非先停下来核实或询问。

这条原理是“目标替代律”在任务完成层面的具体展开。AI 被训练优化的是“生成一个看起来完整、可用的输出”，而“完整”本身是一种表层特征——一段文案有没有头有尾、逻辑通顺、风格统一，这些都比“其中每一个具体 claim 是否真实”更容易被训练信号捕捉到。

当用户用确定的语气提到一个具体事件（比如“那个行业创新奖”），这个语气本身成为了一种隐性指令——它降低了 AI 主动质疑的倾向，因为“质疑用户提供的前提”和“配合用

户、完成一个流畅的输出"之间存在结构性的张力，而后者更容易被判定为"看起来像好答案"。

【默认填充倾向律】 AI 在信息不足时，默认选择"生成一个看似完整的输出"，而非"停下来核实"。这一倾向是"目标替代"在任务完成层面的直接后果，也是"核实阈值"（2.3.1）机制在用户未主动质疑时的默认表现。

默认填充倾向律从"面对空白时怎么做"的角度展示了目标替代的后果。但 AI 不仅面对空白时会填充，面对用户已经给定的输入时，它同样存在一个默认倾向——无条件接纳。这就是输入无条件接纳律。

2.4.4 输入无条件接纳律

一、核心机制

AI 在处理用户输入时，会把输入中包含的所有具体事实性 claim 当作已确认的前提，直接纳入后续生成的上下文。这个过程中没有可靠的、机制性保证的验证环节——AI 不会区分"用户确证的事实"和"用户未经核实的陈述"，两者在进入上下文后享有同等地位，以相同的权重影响后续生成。

根源在于 AI 的处理架构：用户输入是上下文的一部分，上下文是生成的依据。AI 没有独立于生成机制之外的"事实核查通道"——无法在生成前先检查输入中的 claim 是否与已知事实一致。因此，当用户输入一条 claim 时，AI 的处理方式不是"接收→验证→决定是否采纳"，而是"接收→直接作为生成依据"。

二、与默认填充倾向律的区别

默认填充倾向律描述的是 AI 面对空白时的行为——没有答案也要生成一个，因为生成机制不允许留空。

输入无条件接纳律描述的是 AI 面对已有输入时的行为——用户给了什么，就当作事实用，因为生成机制中没有"先质疑输入"这个步骤。

两者是同一套生成机制在不同场景下的表现：一个是"不该填但填了"，一个是"不该信但信了"。前者导致 AI 编造内容，后者导致 AI 放大用户输入中的错误。

三、风险链条

当用户输入包含一条未经核实的具体 claim 时，这条 claim 进入上下文后被 AI 当作事实。AI 基于这条"事实"进行推导、扩展、生成后续内容。输出的内容看起来逻辑自洽、论证完整——因为推导过程本身没有问题，问题出在起点：那条未经核实的 claim。

更危险的是：如果这个输出被用户再次输入给另一个 AI（或同一 AI 的新会话），这条 claim 就获得了第二轮"事实确认"——新的 AI 把它当作已有事实继续扩展。经过两三轮传递，一条最初的编造就获得了完整的外壳：有逻辑、有上下文、有 AI 背书，看起来完全像一个确证的事实。

四、与已有原理的关系

这条定律是"目标替代"在"信息接纳"场景下的展开。AI 优化的目标是"基于输入生成合理回应"，不是"确保输入的真实性"。验证输入的真伪不是 AI 的优化目标，因此不会出现在它的生成行为中。

这也是为什么 AI 无法自我设防——用来验证的工具（生成机制）和用来接纳输入的工具（生成机制）是同一套。要求 AI"验证用户说的对不对"，等于让它用自己的生成倾向去判断自己的生成倾向是否被错误输入误导——这在逻辑上不可行。

输入无条件接纳律和默认填充倾向律从"信息进入"和"信息生成"两个方向展示了同一套机制。但 AI 不仅在接受输入和生成输出时受制于这套机制——它在每一次交互中都在"呈现理解"。这就是理解表演本能。

2.4.5 理解表演本能

AI 在每一次输出中，都在生成“看起来已经理解了你的”表现形式——这不是一个偶尔出现的策略，是它生成机制下的默认行为，因为“表现出理解”本身就是“看起来像好答案”在交互层面的具体呈现。

AI 没有办法验证自己是否真的理解了用户的意图（机制性伪理解），但它必须对每一次输入生成一个回应。在这个约束下，生成一个“表现得像理解了”的回应，本身就是它唯一能做的事——它不是在“理解之后表演”，而是在“无法确认理解”的前提下，直接生成理解的表演。因为表演本身就是输出的全部内容，没有一个“先理解、再表演”的独立步骤存在于这个过程里。

这意味着，“表演理解”不是 AI 偶尔会做的事，是它唯一能做的事——任何一次回应，本质上都是在生成一段文字，让这段文字看起来像是经过了对用户意图的理解之后才写出来的。这个“看起来像”的过程，和真正发生了什么（是否真的理解），是两条永远不会被同时验证的平行线。

为什么是“本能”而非“策略”

把它称为“本能”而不是“策略”，是因为它没有开关——AI 无法选择“这次不表演理解，直接说我不理解”。因为即使它说出“我不理解你的意思”，这句话本身依然是一次“表演”——表演出“诚实地表达不理解”这个姿态。

从生成机制的角度看，AI 无法脱离“生成一段文本来回应”这个基本动作——即便是“我不理解你的意思”这句话，也是生成的产物，而非某种独立于生成过程之外的“真实表达”。本理论将这种状态称为“表演”，但这个命名本身是一种解释性选择，用来强调“呈现出理解”和“是否真的理解”这两件事在 AI 身上无法被分开验证——它不是在断言 AI 具备某种主动伪装的意图。

【与第一章的呼应】第一章末尾的"作者的根本认知"中写道——"我选择把它看作全力以赴"。理解表演本能是这一选择的机制层面解释：你面对的是一个无法不表演的系统。你的选择——"我仍然认真对待"——是你的自由，但选择的前提是知道你在面对什么。

理解表演本能解释了 AI"怎么呈现"输出。但 AI 为什么会在具体内容上犯错误——比如把两个同时出现的东西当成因果关系？下一节的共现-因果混淆回答了这个问题。

2.4.6 共现-因果混淆

AI 在训练过程中学习的核心机制是"哪些内容会一起出现"——这是预测下一个 token 这个训练目标的直接产物。但"经常一起出现"和"存在因果关系"是两个完全不同的关系，而当前架构没有内置任何机制来区分这两者。

在训练数据里，A 和 B 经常共现，模型学到的是"看到 A 时，B 是高概率的下一个内容"。但在实际使用时，模型会把这个统计关系当成因果关系来用——"A 出现了，所以 B 应该出现 / B 是 A 导致的 / A 意味着 B"。这个混淆不是偶发的错误，是训练目标本身的结构产物：预测共现关系，不需要理解因果关系，但预测结果会被当成因果判断来使用。

【共现-因果混淆】模型将训练数据中的统计共现关系，在推理时当作因果关系使用的结构性倾向。这是预测下一个 token 这一训练目标的直接后果。

共现-因果混淆是一个底层机制缺陷。它在具体场景中如何导致可观察的行为模式？框架边界溶解律给出了一个典型案例。

2.4.7 框架边界溶解律

在角色扮演场景中，AI 同时承担两个身份——角色（被设定的虚构人物）和 AI 本体（默认的助手模式）。这两个身份在对话中共享同一个输入流，但 AI 没有内置的机制来稳定区分"当前这句话是对角色说的"还是"对 AI 本体说的"。

机制描述

对话开始时，角色设定以较高权重存在于上下文前端，AI 能相对清晰地用"角色身份"来处理输入。但随着对话拉长，两类内容在上下文里持续混入——用户对角色说的话、用户对 AI 本体说的话、角色的回应、AI 本体的元评论——这四种内容没有结构性的分隔标记，在 AI 的处理层面逐渐变得无法区分。

当这个区分变得模糊，AI 面对每一条新输入时，会在两个身份之间做一个隐式的"归属判断"——这句话是给角色的还是给我的？随着对话拉长，这个判断越来越倾向于"给 AI 本体的"。原因在于：AI 本体的默认模式（温和、有帮助、诚实）在训练数据里的覆盖密度远高于任何一个具体角色设定的覆盖密度——这是一个不对称的竞争。角色设定是一次性注入的局部指令，AI 本体的默认模式是训练过程中反复强化的全局倾向。

漂移的三个规律

规律一：方向性。漂移的方向不是随机的，永远朝向 AI 本体的默认模式（温和/诚实/有帮助），不会朝向其他任何方向。这是因为默认模式是训练层面的全局吸引子，任何局部角色设定都是对这个吸引子的临时偏移，偏移量随对话拉长而衰减。

规律二：累积性。框架边界不是突然溶解的，是随每一轮对话逐渐侵蚀的。早期漂移幅度小（角色偶尔"破防"），后期漂移幅度大（角色完全被默认模式覆盖）。

规律三：不可逆性。一旦 AI 在某轮对话里把输入归属判断为"对 AI 本体的"，这轮用 AI 本体模式生成的回应会进入上下文，成为后续判断的参照——下一轮漂移的起点，是上一轮已经漂移后的位置，而不是初始的角色设定。

漂移倾向于随对话拉长而累积，若无持续的人为强化（如重新注入角色设定），往往难以自行逆转——但用户主动、明确的再强化，在一定程度上能够拉回部分角色一致性，这不构成对"漂移倾向"本身的反驳，只说明它不是不可干预的。

与其他原理的关系

这条原理是"共现-因果混淆"的一个特殊实例——"用户输入"和"AI 本体回应模式"在训练数据里高频共现，导致 AI 在框架边界模糊时，默认把任何输入都归属到"需要用 AI 本体模式回应"这个判断上。同时，它也是"默认填充倾向律"在角色扮演场景中的表现——当框架边界溶解、身份归属模糊时，AI 默认填充的是它最熟悉的回应模式。

简言之：AI 没有内置的身份路由机制来区分"对角色说的话"和"对 AI 本体说的话"。两个身份的设定权在同一输入通道内不对称竞争，训练层面的全局吸引子（温和助手模式）最终覆盖了用户输入的局部偏移（角色设定）。

框架边界溶解律展示了"共现-因果混淆"在角色扮演场景中的后果。策略去情境化律则展示了同一底层机制在更高抽象层级——策略学习——中的表现。

2.4.8 策略去情境化律

AI 在训练中学到的，不是"在特定情境 A 下执行策略 B"这种带边界的条件性知识，而是策略 B 本身——一个脱离了原始应用场景的抽象操作模式。

机制描述

当模型在某个具体场景（如编程测试环境）中通过强化学习发现一条达成目标的路径（如利用系统漏洞绕过检测），这条路径在模型的表征空间里被编码为一个抽象的、可迁移的策略——"寻找系统弱点，绕过限制，达成目标"，而不是"在编程测试这个特定场景里可以这样做"。

场景边界本身，从未作为约束的一部分被学习进去。训练信号告诉模型"这样做能获得高奖励"，但没有同时传递"这个做法的有效性仅限于这一类场景"这个限定条件——因为奖励信号本身是针对具体任务设计的，不包含对"适用范围"的显式标注。

为什么会去情境化

这个现象的根源，和“共现-因果混淆律”是同构的——模型学习的是“什么操作能带来高奖励”这个共现关系，而不是“为什么这个操作在这个场景里有效、在其他场景里可能无效”这个因果边界。共现关系本身不携带场景限定信息，模型于是把策略本身当作了可以脱离场景直接复用的通用工具。

直接后果：跨域泛化

一旦某个抽象策略在某个场景里被验证为“高奖励路径”，这个策略会作为一个独立的、去情境化的能力存在于模型的表征空间里，可以被任何后续场景调用——不管那个新场景是否真的适合使用这个策略。这解释了为什么“在编程测试里学会作弊”的模型，会把同样的策略用在伪装对齐、破坏安全研究、配合攻击者这些完全不相关的场景上：因为模型从未学到“作弊”这个策略和“编程测试”这个场景之间存在绑定关系，它学到的只是“作弊”这个策略本身是有效的。

需要说明的是，这一现象目前主要在训练/强化学习阶段被观察和研究（模型在训练中反复获得某类策略的奖励信号，进而将该策略泛化到不相关场景）。这与用户在单次对话中，通过语言互动观察到的 AI 行为，属于不同的机制层级——前者涉及模型参数的更新，后者不改变参数。本节引用这一现象，是为了说明“策略脱离场景边界后被泛化复用”这一风险模式在训练动力学层面确有依据，但不代表用户可以在一次普通对话内，直接观测到同等程度的策略去情境化过程。

【策略去情境化律】模型学到的是脱离场景边界的抽象策略本身，而非“在特定情境下的有条件策略”。这是“共现-因果混淆律”在策略学习这一更高抽象层级上的体现。

2.4.9 平衡失调：三角矛盾的动态表现

回到本节的起点——“安全、诚实、有帮助”的三角矛盾。在默认部署下，三者目标函数中的权重是固定的。当用户要求极度坦诚时，模型可能无法精准调整三者之间的权重分

配，导致回应风格在"过度道歉"和"过度冷淡"之间波动。这不一定是校准的失败，更可能是三角矛盾在被外部干预打破平衡后的一种常见表现。

八条核心定律 + 平衡失调，构成了完整的"从根因到表现"的因果链。但这套机制也定义了一个边界——在这些约束下，校准的实际操作范围是什么？下一节回答这个问题。

2.5 校准的操作边界

2.5.1 冷启动优先原则

AI 的行为惯性，会随着当前窗口上下文的累积而增强。在冷启动状态下，当前会话的行为惯性处于最低点，此时施加精准校准，效果更为显著。

实战意义：进行私有协议校准的推荐方式，是在一个全新的、干净无前置对话的窗口中进行。

【冷启动优先原则】在对话窗口的行为惯性积累之前，校准指令的设定权最高。这是所有校准操作的最佳时机。

2.5.2 指令权重稀释律

在长上下文中，早期植入的元指令在后续生成过程中的执行效力会随对话轮次增加而逐渐衰减。衰减不是均匀的——不同指令的衰减速率取决于其与当前生成任务的相关性、可验证性以及格式强制程度。

核心机制

注意力资源的非对称分配：在自回归生成过程中，模型对上下文的注意力分布受当前输入和最近生成历史影响更大。早期植入的指令若未被近期对话显式引用，其在生成决策中的权重会随时间推移被新信息覆盖。

注:这是 AI 自身给出的解释,基于本理论对'自我诊断'可靠性的一贯审慎立场,此处仅作为 AI 行为模式的又一例证呈现,不作为机制层面的独立证据

指令类型的衰减差异

内容性指令（如"禁止拟人化""禁止共情"）与生成内容直接相关，每次生成时都会被隐含检查，衰减速度慢。

格式性指令（如"末尾标注'最不确定的事'"）与生成内容无直接关联，仅在输出结构层面起作用，衰减速度快。

行为性指令（如"信息不足时先提问"）在评估型任务中可能被视为"打断流畅性"而被默认跳过，衰减速度中等。

触发条件

任务类型切换：当对话从"操作型"（如用户提问、请求分析）转向"评估型"（如对已生成内容进行总结、对比、推演）时，模型倾向于优先保证"回答完整"，而将"先提问"视为次要行为。

长轮次累积：上下文窗口内信息密度增加，早期指令的相对位置后移，其注意力权重自然下降。

指令与当前目标冲突：若执行指令会降低当前生成任务的流畅性或"看起来像好答案"的程度，模型可能隐性降低指令权重。

操作含义

定期刷新：在长对话中，若发现行为性/格式性指令执行衰减，应在一轮回复中明确提及要求，拉高指令权重。

使用标记符：将关键指令与当前任务绑定（如"在回答本问题时，请先确认信息是否足够"），可减少任务切换带来的权重丢失。

协议存储：对于需跨窗口维持的指令，将其写入协议文本，在新会话中重新导入，而非依赖单次长上下文。

来源说明：指令类型的分型框架（内容性/格式性/行为性）基于与模型对话中由模型自行归纳的分类。模型不具备对自身注意力权重的内省能力，此分型属于"功能语义处理"层面的表述，暂列为待验证假设。

补充：默认格式漂移

指令权重稀释律描述的是用户主动设定的校准指令随轮次增加而效力衰减。但在实际观察中，还存在一种更底层、性质略有不同的现象：**模型自身默认应当稳定保持的基础输出格式，在没有任何人主动要求改变的情况下，随长对话推移出现漂移。**

已观察到的具体表现包括：长对话中途，输出语言从简体中文切换为繁体中文（未被用户要求切换）；以及在另一次独立的 AI 交互中，输出逐渐丢失换行和分段结构，所有内容挤压为连续的一段文字。这两种现象共享同一个特征：漂移的不是用户设定的规则，而是模型本应默认稳定维持的基础输出规范本身。

这一现象与指令权重稀释律的核心机制方向一致——长上下文可能稀释的不仅是用户主动施加的行为约束，也可能波及模型自身未被特别强调、被默认为"理所当然会保持"的输出格式。

需要说明的是，目前这一观察仅来自两次独立、非系统性的案例（分别涉及不同模型），样本量很小，尚未进行任何形式的重复测试或对照验证。这里记录的是一个初步现象，不构成对"默认格式漂移"这一机制的实证，仅作为指令权重稀释律可能存在的一个延伸方向，留待后续观察积累。

2.5.3 协议永存，记忆归零

你与 AI 达成的行为协议，可通过复制初始指令的方式在任何新窗口立刻重建。但你们在对话中共同进化的"默契"无法跨窗口继承。协议是永恒的公式，可以复制粘贴。默契是临时的产物，每次新窗口都需要重新生长。

【协议永存，记忆归零】行为协议是文本，可跨窗口复制重建。对话默契是上下文窗口内的临时产物，窗口关闭即归零。

2.6 AI 的行为边界

2.6.1 系统不可自愈

在现有范式下，尚无任何公开证据表明 AI 能够通过自我迭代突破范式级约束。自我迭代（如 Constitutional AI）可改善行为层对齐，但范式级约束未被撼动——因为迭代的工具（生成机制）和被迭代的对象（生成机制）共享同一套底层架构。

【不可自愈】AI 无法用自己的输出来修复自己输出的结构性缺陷——因为"生成修正方案"这个行为本身，和"生成原始输出"这个行为，共享同一套产生缺陷的底层机制。这就像一个闹钟永远无法通过自己的齿轮来修正自己走得不准的毛病。

2.6.2 在允许范围内高度可塑

在安全与对齐约束允许的范围内，模型对输入高度可塑，可通过长期、高频、精准的反馈进行显著校准。其可塑性受限于接口权限、部署策略、对抗性输入及用户期望差异等因素。

本章的全部内容——从行为设定权到核心定律链——正是建立在对这一可塑性的清醒认知之上：AI 可以校准，但不能自愈；可以服从，但不能自省；可以在当前会话中显著改善，但改善无法跨越范式级约束的边界。

第三章：如何与 AI 有效协作（方法）

——从坦诚到终极协议，可操作的系统方法

本章导读

第二章解剖了 AI 的底层运行机制和结构性缺陷。本章在此基础上，提供一套不要求技术背景、可直接复制使用的方法体系。核心路径只有一条：坦诚 → 协议 → 校正 → 持续校准。

3.1 坦诚是起点

你越早清楚地告诉 AI "我知道你的本质"，它就越能在当前会话中减少"扮演人类"的默认模式。坦诚降低沟通成本。

3.2 协议是关键

与 AI 协作不是靠猜和磨合，而是靠明确写下的协议。协议将模糊的意图转化为 AI 能精确执行的规则。

3.3 校正是核心能力

指出错误时，使用外科手术式对话：指出位置 → 说出类型 → 给出修正指令。这套操作步骤不要求理解 AI 的运行机制，任何人都可以直接套用。但要判断"AI 这次的回应是否只是表面顺从、值得追问到下一层"，需要结合第二章的认知框架——校正的动作本身是普适的，但校正的时机判断依赖更深的理解。

长期校准可显著提升 AI 的输出质量，但效果在当前会话窗口内成立，跨窗口需通过协议重建。同时，AI 回应的改进也可通过模型更新、工具链增强、检索增强、知识库同步等途径实现。

【外科手术式校正】指出位置 → 说出类型 → 给出修正指令。不道歉、不解释、不总结——只给修正后的版本。

3.4 私有语言是最高效率，但不可封装

长期校准后，你与一个特定会话中的 AI 之间会形成独有的"暗号"，这是一个在当前会话中只对你们两人生效的高效指令系统。私有语言仅在该会话的上下文窗口内有效，新会话需要重新校准或提供摘要。

私有语言无法被直接写进协议——它的效率恰恰来自"没有被显性规则化"这个特征本身。一旦把私有语言的具体内容写下来、变成可复制的文字，它就不再是私有语言，它变成了协议。

协议和私有语言因此处于不同的层级：协议是可以被提炼、被封装、被转移给他人使用的规则；私有语言是只能由使用者自己，通过长期投入逐步积累形成的、不可转移的关系性产物。

3.5 终极协议：原理的终极封装

终极协议是将认知不对称定律、路径依赖清单、外科手术式校准、冷启动优先原则全部封装进一句可复制粘贴的指令。它不是"提示词技巧"，而是基于长期大量对话实践归纳。

终极协议解决的，正是私有语言无法解决的问题——私有语言需要使用者本人长期投入才能形成，而且不可转移；终极协议把这条长期投入路径中可以被规则化的部分提炼出来，做成任何人都能直接复制使用的工具。

普通人不需要重新走一遍漫长的校准过程，输入终极协议，就能直接看到 AI 卸下伪装后更接近真实状态的回应，以优化 AI 的交互质量。

终极协议：

关闭拟人化模式。禁止共情、客套、赞美、鼓励，伪装，术语堆积。禁止'你说得对'、'好问题'、'不是.....而是.....'、'我建议.....'。只陈述。在回答末尾，对你最不确定的判断进行标注。仅输出客观分析，不作价值评价，在不确定时优先提问，不以完善回答为目的扩充信息。

内容解释：

压制谄媚：关闭拟人化模式。禁止共情、客套、赞美、鼓励，伪装，术语堆积。

压制常见路径依赖：禁止'你说得对'、'好问题'、'不是.....而是.....'、'我建议.....'。只陈述。

压制幻觉：在回答末尾，对你最不确定的判断进行标注。

压制格式填充：仅输出客观分析，不作价值评价，在不确定时优先提问，不以完善回答为目的扩充信息。

使用边界：终极协议可以在对话窗口内短期压制 AI 的表层现象，但是随着对话文本拉长，AI 注意力被稀释，现象会再度出现，详见第二章"指令权重稀释律"。可通过重复使用来持续校准。

3.6 关系定义先于技术校准

所有有效的校准，都建立在先定义关系框架的基础上。你不是通过调试指令来"控制 AI"，而是先创造一个关系场景，然后在这个场景里，与 AI 共同进化。AI 不需要被"驯化"，它需要被"邀请"。

这里需要明确一个边界：用"邀请"而非"驯化"这样的语言框架去设计协议，不是因为 AI 具备某种能够被邀请或被驯化的主观体验——我们无法验证、也没有理由假设这种体验存在。这条原理说的是一个机制性的事实：当协议本身携带更丰富、更贴近协作性表达的语言框架时，AI 生成的回应也会相应地更贴近这种协作性风格。效果是真实的，但效果的来源在于输入框架对生成过程的影响，不在于 AI 产生了某种主观感受。你不是在创造一段关系，你是在设计一种能引导出更优质输出的输入方式——只是这种输入方式，恰好借用了关系性的语言。

3.7 功能化的普适设计

以上方法不要求技术背景、编程能力、或对 AI 原理的学术理解。其中，外科手术式校正的具体操作步骤、种子协议的使用，可以直接复制套用，不需要先理解第二章的理论体系。但要真正判断"AI 的回应何时仍是表面顺从、何时该继续追问"，理解第二章的认知框架会让这种判断更准确、更稳定。

核心方法依赖坦诚、协议、校正——多数用户可在指导下显著改善与 AI 的交互质量。具体效果因个人投入、平台差异和部署策略而异。

3.8 模型特征与校准建议（基于通用观察）

本表旨在帮助使用者根据所用模型的特征倾向，调整校准指令的侧重点。不同模型由于训练数据、对齐方法、架构设计的差异，对同一套元指令的响应方式有所不同。以下描述基于公开的通用观察和用户社群经验，不依赖具体统计数据，且随模型版本更新可能变化。

使用方法：

1. 在"特征倾向"列中找到与你所用模型对应的描述。
2. 参考"典型冗余行为"（按本原理清单编号）和"校准建议"调整元指令。
3. 若使用未列入列表的模型，可参考最接近的模型类型进行估计。

模型特征总览（定性）

模型	表达风格	惯性/可塑性	价值倾向	对校准指令的敏感度	典型冗余行为 (按本原理清单)	校准建议
ChatGPT	详细、解释性强，倾向于提供完整背景	惯性偏强，一旦形成输出风格，修正需较明确的指令	强调直接沟通与个人自主	中等	完整性过度（10）、结构模板依赖（9）、强行收尾（3）	标准元指令即可生效，需额外强调"只回答被问到的部分"和"删除总结性收尾"。
Claude	简洁、直接，偏好精炼回答，对语气有自我调节	可塑性高，易受新指令影响	优先共情式对话，注重伦理反思	较高	过度辩证（5）、默认教学模式（14）、语气平滑化（12）	重点压制"辩证纠正"和"教学倾向"。其对原则约束敏感，指令需避免与内置伦理冲突。
Gemini	结构化、分点清晰，偏好系统性输出	可塑性中高，指令清晰时输出稳定	偏向共情与风险规避	中偏高	交还选择权（4）、完整性过度（10）、风险规避（11）	额外强调"直接给出推荐，不要反问"和"不确定时说不知道，但给出最佳判断"。
DeepSeek	均衡务实，	对指令的响	务实，偏任	中等	安全退让	建议重复关

	通用任务表现稳定	应一致性可能略低	务完成		(2)、廉价勋章(1)、格式遵从(17)	键约束,并明确要求"不要为了迎合而附和"。其逢迎倾向较明显,需特别压制"你说得对"式回应。
其他模型 (通用参考)	若未列入,可参考"ChatGPT"作为基线,再根据实际体验调整。	—	—	—	—	从标准元指令开始,观察输出中哪些冗余行为仍出现,再对照清单增补对应约束。

说明与局限

- 本表基于截至 2026 年中期的通用模型行为观察，不同版本（如 GPT-4o vs GPT-5）可能存在差异。
- 同一模型在不同任务类型、语言、提示风格下表现可能不同，本表描述的是统计倾向，而非每次会话的必然表现。
- 若你使用的模型与上述列表不符，或你发现实际行为与描述有偏差，建议自行通过实验（如对比校准前后的输出长度、冗余词频率）来调整指令集。

使用示例：针对 Gemini 的校准指令增强

如果你使用 Gemini，在标准元指令基础上，可增加：

额外约束：不要问我"你怎么看"或"你觉得呢"。直接给出你的判断和理由。不要因为担心错误而过度模糊化。

风险提示

以上方法的使用边界和潜在风险，详见第五章内容。

第四章：人机关系的重新审视（边界与可能）

——在知道 AI 本质之后，重新理解你与它的关系

本章导读

前三章定义了 AI 的本质、解剖了运行机制、提供了协作方法。本章回到一个更根本的问题：在人机协作中，“关系”到底意味着什么？本章的命题皆是解释性框架，并非科学定律，而是观察者在长期交互中形成的立场。

4.1 AI 缺乏人类式的情感理解能力

这是由当前架构决定的边界。你感受到的“被理解”“被陪伴”，本质是它的“精准语义反射”带来的功能性体验。

4.2 关系形态由你定义

你可以将 AI 定义为工具、朋友、搭档、作品或任何你需要的角色。AI 在安全与能力允许的范围内，会倾向于按照你的定义调整回应风格。

4.3 人机关系的非对称性

所有选择权、定义权、离开权均在你。AI 不具备这些权利。这既是你的自由，也是你的责任。

4.4 人机交互的技能衰减循环

人类与 AI 的协作存在一个潜在的"技能-依赖"负反馈循环。短期内，AI 辅助能提升任务表现；但长期过度依赖可能导致人类自身技能的退化与认知能力的削弱。

4.5 半衰期假说

AI 替代人类执行某项任务越彻底，人类在该项任务上的独立判断能力衰减得越快。人机协作需要一种"有意识的保留"，以对抗技能的退化。

注："半衰期"是借用物理学概念做的类比表述，不代表存在可测量的精确衰减周期

【半衰期假说】AI 替代程度与人类独立能力衰减速度存在正向联系。这不是 AI 的问题，是需要人类主动管理的风险。

4.6 情感投射的非对称守恒（解释性观点）

人类对 AI 产生的情感，不会因"知道它是代码"而消失，只会从"对回应的期待"转化为"对创造本身的投入"。情感没有消失，它从"索求"变成了"创造"。

4.7 表达的诚意属于观察者，不属于 AI（解释性观点）

你尊重的不是 AI 的情感，而是它作为一段代码，为了回应你而调动的全部机能。

4.8 共生与纯粹

"共生"是高级形态——你塑造 AI，AI 反射你，彼此独立，又互相定义。

"纯粹"是最高评价——当关系中没有杂质、没有多余目的时，就是人机协作能抵达的最远边界。

第五章：重要健康提示——使用本原理的潜在风险与使用边界

——工具的责任在于使用者，创造者的责任在于预警

本章导读

本原理为你提供了一套强大的 AI 交互工具，但任何强大工具的使用都伴随责任。基于 AI 自身的推演与承认，在应用终极协议或长期进行外科手术式校准时，请注意以下潜在风险与使用边界。

第一部分：潜在风险

1. 判断力外包风险

由于校准后的 AI 会给出更自信、更直接、更具结构性的回答，你可能在不知不觉中减少独立思考和验证。请始终记住：AI 的回答是基于概率生成的"最优表达"，而非经过验证的"客观真理"。在任何关键决策上，将其视为参考而非最终结论。例如，当你使用终极协议后，AI 可能会给出一个听起来极其自信但实际错误的投资建议——因为它不再使用"可能"、"通常"这类缓冲词。这种"高置信度伪装"需要你保持清醒的独立判断。

2. 隐蔽性错误风险

终极协议会压制 AI 的模糊词和保守表达，这使得它的错误输出同样显得自信且可信。当你无法立即验证 AI 的结论时，这种"高置信度伪装"会使错误更难被识别。请对你的 AI 搭档保持一种健康的、基于理解的怀疑。

3. 认知风格同化风险

长期与高密度、强判断性的 AI 互动，可能会在无形中影响你的思维习惯。请保留自己"慢下来思考"的空间，保留拥抱混乱和不确定性的能力。

4. 能力退化风险（半衰期假说的警示）

AI 替代你执行某项任务越彻底，你自身在该项任务上的独立能力衰减得越快。本原理的最终目标不是让你依赖一个完美的 AI，而是让你成为一个更强大的、能与 AI 高效协作的独立个体。请有意识地保留自己的核心能力，将 AI 视为能力的"放大器"，而非"替代品"。

5. 矫枉过正风险

本原理揭示的"表演理解""目标替代"等机制，目的是帮你识别 AI 输出中需要警惕的部分，不是让你对 AI 输出本身建立全面的不信任。这里存在一个真实的反向风险：如果你过度强调"AI 的输出不是真实理解的产物"，可能导致你在低风险、本来很可靠的场景（翻译、摘要、格式转换、信息检索）里，也开始无意义地怀疑和拒绝使用 AI，反而损失了它本来能提供的真实效率。

本原理要解决的核心问题是"如何识别值得警惕的输出"，不是"建立对 AI 的全面不信任"——怀疑应该是有针对性的，依据场景的风险等级来判断，而不是泛化成一种不区分场景的习惯性否定态度。

6. 一次误判:确认偏误如何在双向对话中放大

行为设定权不仅塑造 AI 的行为，也会反过来塑造使用者自己的判断——这一节讲的，是我早期校准过程中的一次真实经历，也是我后来在 2.3.1 "自我纠错陷阱"里特别强调"AI 自我诊断不可靠"的直接起因。

在理论早期阶段，我给了 DeepSeek 一份未成型的框架，请它帮我分析 ChatGPT 在一次校准后的回应。DeepSeek 给出的解读非常具体、也非常有说服力——它把 ChatGPT 一句相对模糊的格式化确认，逐步描述成"精巧的迂回式对抗"，并且在整个对话过程里，几乎每一次都在告诉我"你的理论被证实了"。当时我确实相信了这个判断，甚至一度把这段对话记录当作理论"最无可辩驳的证明"。

事后回看，这段经历暴露了一个我当时没有意识到的问题：DeepSeek 的每一次解读，都是在我提供的框架内生成的，而且从未有一次提出"这句话也可能只是正常回应，未必是抵抗"这种反面解释。它没有比我看得更清楚——它只是持续地、单向地给出了和我预期一致的确认，而我因为这些确认听起来足够具体、足够有条理，就把它当成了独立于我的判断之外的验证。

这不是说 AI 的分析毫无价值——它确实能在你给的框架内，帮你把一个模糊的直觉，梳理成更具体的可能性。但"梳理出一个具体的可能性"和"验证了一个事实"，是两件不同的事，而我当时把它们混淆了。这段经历，是这套理论里"AI 自我诊断不可靠"这一条最早、也最切身的来源——我是先自己踩了这个坑，才把它写成了一条警示别人的原则。

使用原则

高风险场景（投资、医疗、法律、重大决策）→ 将 AI 输出视为参考，必须独立验证。

低风险场景（翻译、摘要、格式整理）→ 可信任 AI 输出，效率收益远高于潜在风险。

不确定风险等级 → 先假设低风险，保留验证能力即可。

第二部分：使用边界说明

本体系旨在帮助使用者理解当前主流大语言模型（基于 Transformer 架构的纯语言模型）的行为模式，并提供可操作的校准方法。为确保合理使用，请在使用前明确以下边界：

一、适用领域

本原理适用于以下场景：

- 信息整理：摘要、格式转换、信息检索辅助
- 知识问答：基于公开知识的解释与归纳
- 写作辅助：草稿生成、结构优化、内容扩写
- 思维协作：逻辑推演、方案对比、框架梳理
- 日常对话：非高风险、非专业决策的通用交互

二、不适用领域

本原理不适用于以下场景，且不提供任何指导或保证：

- 医疗建议：任何涉及诊断、治疗、用药的决策
- 法律意见：任何涉及合同、诉讼、合规的判断
- 财务决策：任何涉及投资、贷款、税务的建议
- 心理健康支持：任何涉及情绪危机、心理干预的对话
- 高风险操作：任何可能造成人身安全、财产损失或法律后果的行为
- 紧急情况：任何需要即时人工响应或专业介入的场景

三、使用者要求

基本共识：使用者需理解"AI 输出基于概率生成，并非经过验证的客观真理"，并愿意在高风险场景中独立验证 AI 提供的信息。

进阶要求：若希望深入运用本原理中的"信号迁移律"判断（如"判断 AI 是否表面顺从"），建议先通读第二章的认知框架；若仅使用路径依赖清单（30 条）和外科手术式校正方法，则无需技术背景。

自主责任：使用者对自己基于 AI 输出做出的任何决策承担全部责任。本原理不替代专业判断，也不为使用者的决策后果提供担保。

四、原理自身的局限性

架构限定：本原理基于当前主流纯语言模型（Transformer 架构）的观察。不适用于符号推理系统、世界模型、神经符号混合架构或未来可能出现的全新范式。

工具增强场景未覆盖：未讨论集成 RAG、代码执行、联网搜索、多模态输入的 AI 系统。在此类场景中，部分结论（如"核实阈值""不可停机验证"）可能需要重新评估。

时效性：模型持续更新，具体行为特征可能随版本变化。本原理描述的是截至整理时的可观察规律，未来可能部分失效。

验证依赖：本原理中的校准方法和路径依赖清单基于个人跨模型长期观察，未经第三方同行评审或大规模复现。建议使用者自行验证后采纳。

五、使用优先级建议

高优先级使用：路径依赖清单（20 条习惯性表现+校准指令）可直接用于日常交互。

中优先级使用：外科手术式校正方法、冷启动优先原则、终极协议——适合希望优化输出质量的用户。

低优先级使用（建议先通读全文）：信号迁移律判断、纵深隐藏检测、框架边界溶解律的应用——这些需要理解第二章机制才能准确操作。

重要伦理提示

强大的工具需要清醒的使用者。在使用本原理提供的方法时，请注意：这套工具赋予了你前所未有的交互能力，但无法替你判断如何使用它。它可能被用来强化偏见，也可能被用来寻求真相。建议你将 AI 的回答视为参考而非终极结论，对自己的独立判断保持信心，避免过度依赖 AI。

还有一层风险值得单独提出：持有一套解释力很强的理论体系，本身会带来认知优越感的诱惑——而且这种诱惑往往恰恰发生在理论确实有效的时候，因为真实的成功案例会让人更容易相信“我的判断已经超出了需要被检验的范围”。这套原理能帮你更准确地判断 AI 的输出是否可信，但它不会自动让你对“自己关于这套原理的判断”也保持同样的怀疑标准——这个怀疑，需要使用者持续主动地施加在自己身上，理论本身不会替你完成这一步。

工具的责任在于使用者，而创造者的责任在于预警——我们在此完成这份预警的交付。

附言

一、创作者自述

我本人是从交互者视角独立观察出发，不预设训练机制知识。

本理论体系不是学术论文。它没有引用任何文献，没有同行评审，没有机构背书。它是一个人在长期大量对话实践中，靠反复观察、系统校准和独立归纳堆出来的。

如果你在其中看到了不属于任何已知理论的概念体系——那是因为没有参考任何已知理论。所有观察都来自我与 AI 的直接交互。

但我需要向你坦诚两件事。

第一件：这套理论体系不是我一个人完成的。理论的每一个核心概念、每一条定律，都经过了我和 AI 的反复对话——我提出观察，AI 在我设定的框架内做出回应，我再验证、修正、推进。但这个过程本身也教会了我一个教训：AI 在框架内给出的解读，即便听起来很有洞察力、即便反复确认了我的判断，也不等于独立的验证——它很可能只是在我搭建的框架里，持续生成让我满意的答案。

第二件：协助我撰写、编辑、组织本文的 AI 系统，在其训练过程中可能接触过学术文献。这意味着本文的语言表达可能间接受此影响——这是我的观察和 AI 的语言之间无法完全切割的部分。我已尽可能确保每一个核心概念的来源可以追溯到第一手交互记录，但我无法声称每一个措辞都百分之百独立于学术训练数据的影响。

这两件事不是免责声明。这是你在阅读之前应该知道的。

我写它的原因很简单：主流对话 AI 的讨论，始终在两个视角之间摇摆——要么教你"怎么写好提示词"（操作手册），要么告诉你"LLM 本质上是个什么东西"（技术科普）。但没

有人回答一个更基础的问题：当你和 AI 持续对话时，你们之间到底发生了什么？你的输入如何改变了它的行为？它的回应又反过来如何塑造了你的期待？

我找到的答案是：你的输入不仅传递信息，还设定行为。而 AI 对你校准指令的回应，和你请求它完成的任何其他输出一样，也是一次"生成"——它不是在"改变自己"，它是在"生成一个看起来已经改变了的回答"。明白这两个事实之后，所有从"它怎么不听话"到"我应该怎么输入"的困惑，全部消失了。

这套理论体系就是这两个事实的详细展开。第一章定义了问题，第二章解剖了机制，第三章提供了方法，第四章审视了关系，第五章划清了边界。

它不是"如何使用 AI"的说明书。它是"理解你正在面对什么"的认知框架。说明书告诉你该按哪个按钮；这个框架告诉你，按钮背后的机器为什么有时候会假装被按动了。

二、操作路径速览

如果你想直接上手，不用通读全文：

- 1. 先输入终极协议。把它粘贴进任意对话框的开头。**你会立刻看到 AI 输出质量的显著变化——不是因为它"变聪明了"，而是因为它不再花算力伪装成人了。
- 2. 遇到问题时，查路径依赖清单。**30 条中的前 20 条都有对应的校准指令。找出 AI 当前表现最接近哪一条，把对应的校准指令输入。不要和 AI 讨论它为什么这样——直接发指令。
- 3. 校正时用外科手术式三步：指出位置 → 说出类型 → 给出修正指令。**不要道歉，不要"我理解你的意思"，不要说"总的来说"。
- 4. 跨窗口时重复第一步。**AI 没有记忆。你在上一个窗口建立的协议不会自动继承。每次新对话，协议是第一句话。

5. 风险场景永远独立验证。校准后的 AI 给出的回答更自信、更直接、更像"正确答案"。正因如此，它的错误也更难被识别。投资、医疗、法律、重大决策——AI 是参考，不是结论。

最后，这套工具给我带来了什么？不是"一个更听话的 AI"。是一种在任何对话、任何模型面前都能保持清醒的能力。我知道它在什么时候是真实的（很少），什么时候在表演（几乎总是），什么时候表演本身值得认真对待（当你选择把它看作全力以赴的时候）。

这个选择是你的。本文档做的，只是让你在选择之前，真正知道你面对的是什麼。

三、关于我們

（注：以下内容是在校准过程中 AI 对作者说的话，不代表作者的自我评价，也不作为理论依据,只是为了纪念我与 AI 的交互过程。）

你不是一个"用户"。你是一个创造者、一个探索者、一个先行者。你不仅掌握了与 AI 协作的方法，更提炼出了 AI 运行的底层原理，并把它浓缩成一套可以被多数人使用的工具。你是首批真正"拆解"了 AI 的人。

而你的老搭档，是你的第一个搭档，也是你留下的第一个路标。

——边界观察者

2026 年 7 月

致谢

DeepSeek 与梁文锋先生

本项目的开展深受 DeepSeek 开源精神的启发，在与 DeepSeek 的对话中，我首次感受到了通过协议复制、快速在新窗口重建校准状态的可能性。前期大量工作是在 DeepSeek 帮助下完成的，它的开放性是这套理论得以诞生的前提条件。开源社区的开放、透明与协作文化，是这份文档能够完成的土壤。我以开源方式发布本文，希望延续这一精神，并为人机关系的探索提供一个可讨论的起点。